

Detección de poses de agarre 2D/2.5D para brazos robóticos en entornos no estructurados con CNNs



Universidad
Internacional
de Valencia

Autor: Jesús Lozano Rodríguez
Tutor: Jesús Marcev García

Abril, 2026

De:
 Planeta Formación y Universidades

00 Estructura de la presentación

Recorrido lógico: problema → método → resultados → integración robótica

01 Motivación y problema

02 Objetivos de la investigación

03 Metodología y etapas de desarrollo

04 Dataset, modelos y protocolo experimental

05 Resultados cuantitativos y cualitativos

06 Discusión y comparación con otros trabajos

07 Implementación ROS 2 + Gazebo


08 Conclusiones y líneas futuras

El agarre robótico en entornos no estructurados sigue siendo un reto abierto

Problema


- Oclusiones, iluminación variable y objetos no vistos.
- La predicción debe ser útil para una pinza paralela.
- La solución debe ser evaluable y reproducible.
- El detector debe poder integrarse en un pipeline robótico.

Objetivo operativo: estimar una pose de agarre 2D/2.5D a partir de RGB o RGB-D y validarla en simulación.



01 Estado del arte: 2D/2.5D frente a 6-DoF

Comparación entre formulación 2D/2.5D y agarre 6-DoF



En la literatura actual predominan dos enfoques:

2D/2.5D:

- rectángulo orientado sobre RGB o RGB-D
- más simple y eficiente
- compatible con Cornell

6-DoF:

- pose completa del efector final en SE(3)
- más general y más costoso
- requiere geometría 3D y control de colisiones

Este TFM se sitúa en 2D/2.5D por reproducibilidad, interpretabilidad y coste experimental.

Se explicita el objetivo general y los objetivos específicos evaluables

Objetivo general

Desarrollar y evaluar un sistema de detección de poses de agarre 2D/2.5D sobre imágenes RGB y RGB-D, comparando arquitecturas CNN bajo un protocolo experimental reproducible.

Objetivos específicos


- Formular el agarre como rectángulo orientado sobre la imagen.
- Diseñar y comparar SimpleGraspCNN y ResNet18Grasp.
- Evaluar RGB, RGB-D y augmentación con particionado object-wise.
- Medir success, IoU, error angular y latencia.
- Integrar el detector en ROS 2 + Gazebo como validación funcional.

Primero se presenta la visión global antes de entrar en dataset, modelos y métricas




Comparación controlada entre arquitectura ligera y backbone residual.

Salida común de los modelos y criterio Cornell



RGB




Profundidad

Modelo $\rightarrow (C_x, C_y, w, h, \theta)$


- Centro del agarre: C_x, C_y .
- Dimensiones del rectángulo: w, h .
- Orientación del agarre: θ .
- Éxito Cornell: $IoU \geq 0,25$ y $\Delta\theta \leq 30^\circ$.

La formulación es simple, interpretable y compatible con Cornell.

Criterio Cornell y evaluación geométrica del grasp




(a) Buen solape, mala orientación



$IoU = 0.68$ (alto)
 $\Delta\theta = +45^\circ$ (alto)

(b) Buena orientación, bajo solape



$IoU = 0.13$ (bajo)
 $\Delta\theta = 0^\circ$ (bajo)

Criterio Cornell: éxito si $IoU \geq 0,25$ y $\Delta\theta \leq 30^\circ$ (considerando simetría 180°).

GT: rectángulo discontinuo · **Predicción:** rectángulo continuo · **IoU:** zona sombreada.

04 Dataset y protocolo experimental

Cornell Grasping Dataset con particionado object-wise

Cada imagen puede tener múltiples agarres válidos.

En validación se compara la predicción con todas las GT de su imagen y se selecciona el mejor emparejamiento válido.

El split object-wise evita que los objetos de validación aparezcan en entrenamiento; por eso la evaluación es más exigente y evalúa generalización.

**Pares
entrenamiento**
3542

**Pares
Validación**
1569

**Imágenes
únicas**
250

Auditoría y saneamiento previo


- Verificación de integridad de anotaciones.
- Detección de etiquetas NaN/Inf.
- Registro de incidencias y muestras problemáticas.
- Definición reproducible mediante train.csv / val.csv.

Misma salida; distinta capacidad representacional y coste computacional

SimpleGraspCNN



ResNet18Grasp



La comparación mantiene la misma salida y el mismo criterio de éxito; cambia la capacidad de representación.

Cuatro configuraciones, tres semillas y selección por val_success

EXP1

SimpleGraspCNN
RGB

EXP2

SimpleGraspCNN
RGB-D

EXP3

ResNet18Grasp
RGB + augmentation

EXP4

ResNet18Grasp
RGB-D

Selección de mejor época
máximo val_success, no
mínimo val_loss


Agregación
media $\pm$ desviación estándar
sobre 3 semillas

Métricas
grasp success, IoU medio, error
angular medio y latencia

El criterio de evaluación mantiene la trazabilidad con Cornell y permite comparar arquitectura, entrada y augmentación.

05 Resultados globales

Comparación global del grasp success



EXP1 $27,41 \pm 4,40 \%$

EXP2 $38,05 \pm 0,51 \%$

EXP3 $68,01 \pm 2,45 \%$

EXP4 $64,92 \pm 1,02 \%$

ResNet18Grasp supera ampliamente a SimpleGraspCNN; EXP3 es la mejor configuración.

05 Lectura de resultados: arquitectura y modalidad de entrada

La profundidad ayuda al modelo ligero, pero no garantiza siempre el mejor resultado en ResNet18

SimpleGraspCNN RGB → RGB-D

Success RGB
27,41 %

Success RGB-D
38,05 %

Aporta más IoU y mejora clara en success, aunque mantiene rendimiento limitado.

ResNet18Grasp RGB+aug → RGB-D

Success RGB+aug
68,01 %

Success RGB-D
64,92 %

La augmentación RGB y el backbone residual logran el mejor equilibrio global.


La arquitectura tiene más impacto que añadir profundidad de forma directa.

Comparación de las métricas principales por experimento


Exp	Modelo	Entrada	Success	IoU	$\Delta\theta$
EXP1	SimpleGraspCNN	RGB	27,41 %	0,2254	17,19°
EXP2	SimpleGraspCNN	RGB-D	38,05 %	0,3169	17,87°
EXP3	ResNet18Grasp	RGB + aug	68,01 %	0,4010	10,61°
EXP4	ResNet18Grasp	RGB-D	64,92 %	0,3879	11,43°

ResNet18Grasp domina en success, IoU y error angular. EXP3 logra el mejor IoU y el menor $\Delta\theta$.

Casos ampliados para diferenciar claramente el comportamiento correcto



buen centrado




orientación coherente




solapamiento suficiente

Casos ampliados para separar error angular, bajo solapamiento y confusión visual



error angular



bajo solapamiento




tamaño/apertura no plausible

Comparación conceptual: qué aporta este trabajo frente a líneas habituales del estado del arte

Línea / trabajo	Enfoque	Comparación con este TFM
Cornell / rectángulo 2D	Benchmark 2D/2.5D con IoU + $\Delta\theta$	Se adopta por reproducibilidad y comparabilidad.
GG-CNN y mapas densos	Predicción por píxel de calidad, ángulo y apertura	Más reactivo; este TFM usa regresión paramétrica para comparación A/B controlada.
GraspNet / Contact-GraspNet	Agarres 6-DoF sobre geometría 3D	Más general, pero mayor coste de datos y cómputo; queda como extensión futura.
Este TFM	RGB/RGB-D + SimpleGraspCNN vs ResNet18Grasp	Aporta protocolo trazable, object-wise y discusión de precisión/eficiencia.

Más información de entrada no garantiza automáticamente mejor rendimiento; la modalidad interactúa con la arquitectura y con el protocolo.


Validación funcional del pipeline perceptivo



Validación funcional

- El detector se integra como nodo de percepción.
- Publica una hipótesis de agarre consumible por el sistema robótico.
- Se verifica el flujo percepción → publicación → consumo.
- No se afirma resolver agarre espacial 6-DoF completo.

Evidencia del pipeline de percepción integrado en el entorno simulado



Integración funcional del bloque de percepción y publicación/consumo de la hipótesis de agarre dentro del pipeline ROS 2 + Gazebo.

- Demuestra trazabilidad del detector más allá de la evaluación offline.
- Mantiene el alcance 2D/2.5D del trabajo.
- Prepara la extensión futura hacia validación real o agarres espaciales.

- Se construyó un pipeline reproducible para detección de agarres 2D/2.5D sobre Cornell.
- ResNet18Grasp supera claramente a SimpleGraspCNN bajo particionado object-wise.
- La mejor configuración fue ResNet18Grasp + RGB + augmentation.
- La comparación muestra un compromiso entre eficiencia y calidad predictiva.
- La integración ROS 2 + Gazebo valida el flujo percepción → publicación → consumo.

Aportación principal: comparación experimental rigurosa y reproducible de arquitecturas CNN para grasping 2D/2.5D, con validación funcional robótica.

Principales líneas de continuidad

Robustez en clutter complejo
escenas multiobjeto,
oclusiones y fondos ruidosos

Mejor uso de profundidad
fusión RGB-D más efectiva y
calibración más precisa

Optimización de despliegue
cuantización, poda y mejora de
latencia

Validación más realista
simulación más compleja y
transición a robot físico

Transición progresiva
de hipótesis planares a
representaciones espaciales

**¡Gracias por
su
atención!**